

# Predicción del ingreso en Bogotá: resultados


0,5384

RMSE de validación


Ridge con selección hacia atrás

Las variables laborales y las interacciones mejoran el pronóstico. La ventaja entre las mejores variantes es mínima.

**(a) Los bloques siguen el calendario de la encuesta**



**(b) 3,217-3,218 personas por bloque**



# Anexo: muestra y población representada

$$n = \sum_i 1, \quad \hat{N} = \sum_i w_i, \quad w_i = \text{fex\_c}_i$$

| Población cubierta         | Registros | Personas representadas |
|----------------------------|-----------|------------------------|
| Base consolidada           | 32.177    | 8.164.164              |
| Ocupados de 18 años o más  | 16.542    | 4.120.583              |
| Ingreso positivo observado | 14.764    | 3.686.676              |

IC del total: no estimable con el diseño disponible. Faltan estratos, conglomerados completos o pesos replicados.

# La separación de datos define la evaluación

| Uso           | Bloques | Registros | Suma de fex_c |
|---------------|---------|-----------|---------------|
| Entrenamiento | 1 a 7   | 10.263    | 2.499.677     |
| Validación    | 8 a 10  | 4.500     | 1.186.729     |

$$\text{RMSE}_V = \sqrt{\frac{1}{n_V} \sum_{i \in V} (y_i - \hat{y}_i)^2}$$

La selección minimiza error por registro, sin fex\_c. El RMSE ponderado se reporta como sensibilidad poblacional.

# Las variables deben aportar información disponible

## Información económica

Edad y escolaridad.

Horas, antigüedad y segundo empleo.

Vínculo, ocupación, tamaño de firma y formalidad.

Estrato y características del hogar.

## Flexibilidad controlada

Polinomios y bases cúbicas por tramos.

Interacciones de características personales y laborales.

Categorías de ocupación más detalladas.

Se excluyen ingresos derivados, identificadores y variables que revelarían la respuesta.

# Ridge limita la complejidad de las interacciones

$$(\hat{\alpha}, \hat{\beta}_{\lambda}) = \operatorname{argmin}_{\alpha, b} \left[ \sum_{i \in T} (y_i - \alpha - x_i' b)^2 + \lambda \sum_j s_j^2 b_j^2 \right]$$

Qué se penaliza

La magnitud de los coeficientes, ajustada por la escala de cada columna.

El intercepto queda sin penalizar.

Qué se selecciona

25 valores de  $\lambda$  entre 0,01 y 10.000.

El modelo elegido usa  $\lambda = 100$  y 338 columnas.

# La selección de grupos busca modelos compactos

| Método   | Punto de partida   | Movimiento      | Modelo final |
|----------|--------------------|-----------------|--------------|
| Adelante | Constante          | Agrega grupos   | R5           |
| Atrás    | Diseño ampliado    | Retira grupos   | R6           |
| Mixto    | Resultado adelante | Agrega o retira | R7           |

LOOCV orienta la búsqueda en entrenamiento. El RMSE de validación elige entre las especificaciones finales.

# Todas las referencias se reestiman en entrenamiento

| Modelo | Especificación                   | RMSE validación |
|--------|----------------------------------|-----------------|
| M0     | Media de entrenamiento           | 0,9151          |
| M1     | Edad y edad <sup>2</sup>         | 0,8919          |
| M2     | Edad, horas y vínculo            | 0,8118          |
| M3     | Brecha sin controles             | 0,9066          |
| M4     | Controles S5 aditivos            | 0,6230          |
| M4i    | S5 con perfiles por sexo         | 0,6226          |
| M1w    | Edad y edad <sup>2</sup> (fex_c) | 0,8919          |
| M2w    | Edad, horas y vínculo (fex_c)    | 0,8116          |
| M3w    | Brecha sin controles (fex_c)     | 0,9066          |
| M4w    | Controles S5 aditivos (fex_c)    | 0,6231          |
| M4iw   | S5 con perfiles por sexo (fex_c) | 0,6227          |
| M5     | Recursos y antigüedad cuadrática | 0,5738          |

Modelos w: ajuste representa  $\approx 2.499.677$  personas. RMSE: 4.500 registros de validación.




# R6 alcanza el menor error entre 24 especificaciones

| Modelo | Especificación                         | RMSE validación |
|--------|----------------------------------------|-----------------|
| M6     | Polinomios cúbicos                     | 0,568441        |
| M7     | Polinomios de grado cuatro             | 0,567929        |
| M8     | Bases cúbicas por tramos               | 0,567399        |
| M9     | Interacciones y ocupación detallada    | 0,554133        |
| R1     | Ridge sobre polinomios de grado cuatro | 0,567907        |
| R2     | Ridge sobre interacciones y oficio     | 0,552263        |
| R3     | Ridge con interacciones ampliadas      | 0,546116        |
| R4     | Ridge con escolaridad y jornadas       | 0,538877        |
| R5     | Ridge, selección adelante              | 0,538454        |
| R6     | Ridge, selección atras                 | 0,538444        |
| R7     | Ridge, selección mixto                 | 0,538454        |
| M10    | MCO, grupos elegidos hacia adelante    | 0,543175        |

Entrenamiento: 10.263 registros. Validación: 4.500 registros. Fuente: GEIH 2018, Bogotá.

MCO y ridge: ajuste y evaluación




# LOOCV y validación responden a ejercicios distintos

$$\text{RMSE}_{\text{LOO}} = \sqrt{\frac{1}{n_T} \sum_{i \in T} \left( \frac{e_i}{1 - h_{ii}} \right)^2}$$

| Evaluación de R6                                | RMSE   |
|-------------------------------------------------|--------|
| LOOCV con diseño y $\lambda$ fijos              | 0,5054 |
| CV de 5 particiones, reaprende transformaciones | 0,5501 |
| Validación, sin ponderar                        | 0,5384 |
| Validación, con <code>fex_c</code>              | 0,5342 |


El RMSE ponderado de validación representa  $\approx 1.186.729$  personas.

# Las horas aportan más a la precisión predictiva



Horas totales: aumento medio de 0,1072 en RMSE. La importancia es predictiva, sin interpretación causal.

# Más horas se asocian con mayor ingreso predicho



Promedio sobre los demás atributos observados. La curva describe log-ingreso, sin convertirlo a ingreso medio en pesos.

Entrenamiento: 10.263 registros. Validación: 4.500 registros. Fuente: GEIH 2018, Bogotá.

# Resultados y perfil DIAN

## Resultados

Ridge R6 reduce el error frente a las referencias.

Horas y educación concentran buena parte de la información predictiva.

R5, R6 y R7 casi empatan.

Los resultados obtenidos para Bogotá muestran que las horas trabajadas y los años de educación aportan información importante para predecir el ingreso laboral. La DIAN podría utilizar un modelo de este tipo para identificar personas cuyo ingreso declarado sea considerablemente menor al predicho según sus características y priorizar la revisión de posibles casos de subreporte. Esta sería una aplicación potencial: el ejercicio predice ingresos, pero no demuestra quién declara incorrectamente.

# Perfil de interés DIAN

# Anexo: dos medidas de importancia


$$I_j = \frac{1}{B} \sum_{b=1}^B [\text{RMSE}_V(\hat{f}, X_j^{\pi_b}) - \text{RMSE}_V(\hat{f}, X)]$$

$$J_j = \text{RMSE}_V(\hat{f}_{-j}, X_{-j}) - \text{RMSE}_V(\hat{f}, X)$$

| Horas totales                 | Aumento del RMSE |
|-------------------------------|------------------|
| Permutar y mantener el modelo | 0,1072           |
| Eliminar y reajustar          | 0,0405           |



# Anexo: elección de la penalización de R6



$\lambda = 100$ . Diseño de 338 columnas y 263,91 grados de libertad efectivos.

## Anexo: evaluación poblacional con fex\_c

$$\text{RMSE}_{V,w} = \sqrt{\frac{\sum_{i \in V} w_i (y_i - \hat{y}_i)^2}{\sum_{i \in V} w_i}} = 0.5342$$

| Partición     | Registros | Personas representadas |
|---------------|-----------|------------------------|
| Entrenamiento | 10.263    | 2.499.677              |
| Validación    | 4.500     | 1.186.729              |

El archivo no permite estimar un IC de diseño para estos totales de personas.

# Anexo: fuentes y equipo

GEIH 2018, Bogotá. Microdatos y materiales del curso.  
Repositorio público: [ethramos74/BDML-PS01](#)  
Cifras y ecuaciones reproducibles en el cuaderno del punto 3.

Integrante 1: Jhon Sebastián Vela Salcedo.

Integrante 2: Ethan Arturo Ramos Benitez.

Integrante 3: Harold Santiago Aguilera Mulfo.

Integrante 4: Cesar Augusto Vallejo Quiroga.